Optimization of Iron Concentrate Percentage Using Machine Learning / Optimización del % de Hierro en Concentrado usando Machine Learning

Proyecto aplicado en contexto industrial

Fabio Lopez - October 2025





Project Overview / Visión General del Proyecto

Business Context / Contexto del Negocio

The flotation process in mineral beneficiation plants plays a crucial role in optimizing metal recovery and product purity. Efficient control of process variables can lead to increased iron concentrate quality and reduced silica content — two key metrics for production value.

El proceso de flotación en plantas de beneficio mineral es fundamental para optimizar la recuperación del metal y la pureza del producto. Un control eficiente de las variables del proceso puede mejorar la calidad del concentrado de hierro y reducir el contenido de sílice, dos métricas clave en la rentabilidad de la producción.

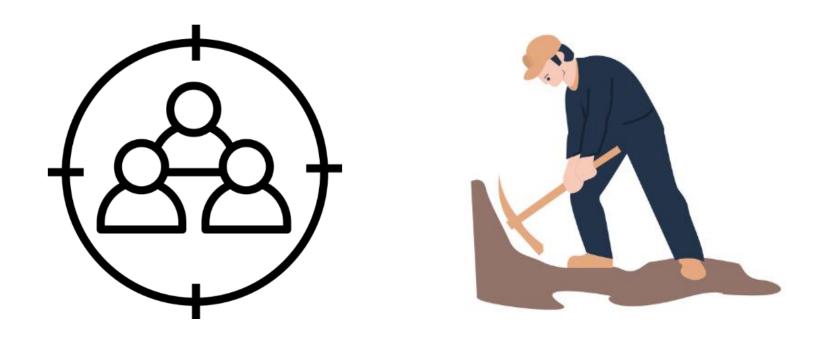
Project Objective / Objetivo del Proyecto

- To develop a machine learning-based solution capable of:
- Predicting % Iron Concentrate from controllable process variables.
- Detecting anomalies in production that may indicate process deviations.
- Optimizing input parameters to maximize concentrate quality.

- Desarrollar una solución basada en machine learning capaz de:
- Predecir el porcentaje de concentrado de hierro a partir de variables del proceso controlables.
- Detectar anomalías que puedan indicar desviaciones en la producción.
- Optimizar parámetros de entrada para maximizar la calidad del concentrado.

Target Audience / Audiencia objetivo:

Data science recruiters, production engineers, and operations managers in the mining and metallurgical sectors.



Dataset Overview / Descripción del Conjunto de Datos

- Dataset Overview
- **Source:** Real industrial data from a flotation plant (available online).
- File: MiningProcess_Flotation_Plant_Database.csv
- **Total Records:** 736,282
- **Time Range:** March 10, 2017 onward (hourly records)
- Features:
 - Inputs:
 - % Iron Feed
 - % Silica Feed
 - Starch Flow
 - Amina Flow
 - Ore Pulp pH
 - Ore Pulp Density
 - Flotation Column 01 Air Flow
 - Targets:
 - % Iron Concentrate
 - % Silica Concentrate



Descripción del Dataset

• Fuente: Datos industriales reales de una planta de flotación (disponible en línea).

• **Archivo:** MiningProcess_Flotation_Plant_Database.csv

• Total de Registros: 736,282

Rango de Tiempo: Desde el 10 de marzo de 2017 (registros por hora)

Variables: Entradas:

- % Hierro en la Alimentación
- % Sílice en la Alimentación
- Flujo de Almidón
- Flujo de Amina
- pH de la Pulpa de Mineral
- Densidad de la Pulpa
- Flujo de Aire de la Columna de Flotación 01

Salidas:

- % Hierro en el Concentrado
- % Sílice en el Concentrado



Data Cleaning & Exploratory Data Analysis (EDA)/ Limpieza de Datos y Análisis Exploratorio

Data Cleaning:

- Converted commas to decimal points for numeric consistency.
- Removed rows with missing or invalid data.
- Selected relevant features and target variables.
- Ensured all data types were correctly set for modeling.

Limpieza de Datos:

- Se reemplazaron comas por puntos para uniformidad numérica.
- Se eliminaron filas con datos faltantes o inválidos.
- Se seleccionaron variables relevantes para el modelo.
- Se aseguró que todos los tipos de datos estuvieran correctos para el modelado.

- Exploratory Data Analysis (EDA)
- Examined distributions and ranges of features.
- Identified correlations between inputs and target (% Iron Concentrate).
- Detected and handled outliers.
- Visualized key variables for insights (histograms, scatter plots).
- Análisis Exploratorio de Datos (EDA)
- Se examinaron distribuciones y rangos de las variables.
- Se identificaron correlaciones entre entradas y el objetivo (% Hierro en Concentrado).
- Se detectaron y gestionaron valores atípicos.
- Se visualizaron variables clave para obtener insights (histogramas, gráficos de dispersión).

Predictive Model & Results/Modelo Predictivo y Resultados

- Model Used: Random Forest Regressor
- Captures nonlinear relationships between variables.
- Robust to overfitting with proper tuning.

- Modelo Utilizado: Random Forest Regressor
- Captura relaciones no lineales entre variables.
- Robusto contra el sobreajuste con ajuste adecuado.

- Performance Metrics:
- Mean Squared Error (MSE): 0.0532 (low error)
- R² Score: 0.9574 (explains 95.74% of variance)

- Métricas de Desempeño:
- Error Cuadrático Medio (MSE): 0.0532 (error bajo)
- R² Score: 0.9574 (explica 95.74% de la varianza)

Interpretation/Interpretación:

- Model predicts % Iron Concentrate accurately.
- High R² indicates strong explanatory power.
- Suitable for process optimization.

- El modelo predice con precisión el % de Hierro en Concentrado.
- R² alto indica fuerte poder explicativo.
- Adecuado para la optimización del proceso.

Process Optimization Results/Resultados de la Optimización del Proceso

- Optimization Goal:
- Maximize % Iron Concentrate by adjusting process parameters.

- Objetivo de la Optimización:
- Maximizar el % de Hierro en Concentrado ajustando los parámetros del proceso

Optimal Parameters Found:

• Ore Pulp pH: **10.50**

Starch Flow: 5036 units

• Amina Flow: **346** units

Air Flow: 360 units

• % Iron Feed: **57.98**%

• % Silica Feed: **22.76%**

• Pulp Density: **1.76**

Parámetros Óptimos Encontrados:

• pH Pulpa de Mineral: **10.50**

• Flujo de Almidón: **5036** unidades

• Flujo de Amina: **346** unidades

• Flujo de Aire: **360** unidades

% Alimentación de Hierro: 57.98%

% Alimentación de Sílice: 22.76%

• Densidad de Pulpa: 1.76

Result:

Maximum predicted % Iron Concentrate: 66.52%

Resultado:

% Máximo predicho de Hierro en Concentrado: 66.52%

Conclusions & Next Steps/Conclusiones y Próximos Pasos

Conclusions:

- Machine Learning model accurately predicts % Iron Concentrate with high R² (0.96).
- Optimization identified key process parameters to maximize iron recovery.
- Implementing recommended settings can improve concentrate quality and process efficiency.

Conclusiones:

- El modelo de Machine Learning predice con precisión el % de Hierro en Concentrado con un R² alto (0.96).
- La optimización identificó parámetros clave del proceso para maximizar la recuperación de hierro.
- Implementar los ajustes recomendados puede mejorar la calidad del concentrado y la eficiencia del proceso.

Next Steps:

- Validate optimized parameters with pilot or plant trials.
- Integrate predictive model into process control systems for real-time adjustments.
- Continue data collection to refine and improve the model.
- Explore applying ML to other flotation variables or downstream processes.

Próximos Pasos:

- Validar los parámetros optimizados con pruebas piloto o en planta.
- Integrar el modelo predictivo en los sistemas de control para ajustes en tiempo real.
- Continuar con la recolección de datos para refinar y mejorar el modelo.
- Explorar la aplicación de ML en otras variables de flotación o procesos posteriores.

Thank You & Final Remarks/Agradecimientos y Comentarios Finales

Thank you for your attention!

This project reflects my ability to apply data analytics and machine learning techniques
to solve real-world industrial problems.
 I'm ready to contribute as a **Data Analyst**, and I'm fully committed to continue learning
and adapting to any technical or business need.

Let's talk about how I can add value to your team!

¡Gracias por su atención!

Este proyecto demuestra mi capacidad para aplicar análisis de datos y técnicas de machine learning a problemas reales del entorno industrial.
Estoy listo para aportar como **Analista de Datos**, y tengo toda la disposición para seguir aprendiendo y adaptarme a cualquier necesidad técnica o del negocio.

¡Conversemos sobre cómo puedo aportar valor a su equipo!

